





Objek	Keterangan
	3. Destructible Box Objek ini adalah sebuah kotak yang ketika dihancurkan oleh pemain memperoleh “Data” dan darah (<i>Health</i>) untuk pemain.
	4. Laser Laser adalah salah satu objek tantangan yang dapat menyerang dan melukai karakter pemain dalam <i>game</i>.
	5. Wall Objek ini berperan sebagai tantangan maupun pembantu untuk menghalau musuh dalam arena.
	6. Arena Door Objek ini berperan sebagai tantangan pintu yang terdapat pada setiap arena dan terbuka jika pemain telah menyelesaikan objektif atau membunuh seluruh musuh.

3.3 Reinforcement Learning (RL)

Setelah langkah sebelumnya menjabarkan keseluruhan alur *pre-production*, kemudian merancang sistem *reinforcement learning*. Pada bagian ini dilakukan langkah-langkah penerapan *reinforcement learning* pada sistem AI *game*.

Merujuk kembali pada algoritma *reinforcement learning* yang di mana memiliki berbagai algoritma berdasarkan dua tipe *policy* yakni *on-policy* dan *off-policy* [32]. Dari kedua tipe algoritma tersebut, terdapat dua algoritma yang lumrah digunakan, yakni PPO dan SAC. Kedua algoritma ini telah diteliti dan diuji pada penelitian yang berjudul “*Comparative Study of SAC and PPO in Multi-Agent*

Reinforcement Learning Using Unity ML-Agents” tahun 2023. Penelitian tersebut menyimpulkan bahwa meskipun algoritma SAC memiliki performa 50% lebih baik dari pelatihan yang diperlukan, namun PPO memiliki stabilitas dan efisiensi yang lebih baik dikarenakan PPO merupakan algoritma *on-policy*, dibandingkan dengan SAC yang merupakan algoritma *off-policy*. Selain itu, PPO memiliki sifat yang lebih agresif terkait menyerang atau menghadapi lawan yang cocok dengan masalah pada game *Code Crusader: Anti-Virus Assault* [36]. Oleh karena itu berdasarkan kesimpulan di atas, algoritma PPO digunakan dalam penerapan *reinforcement learning* pada penelitian ini dan berfokus pada penerapan sistem AI *normal enemy*. Berikut adalah tahapan penerapan *reinforcement learning*.

3.3.1 Environment and Task Specifics

Pada tahapan ini dilakukan penjabaran mengenai *environment* yang berisikan dunia dan objek apa saja yang digunakan dan *task specifics* yang berisikan *state*. Berikut adalah *environment* dan *state* yang digunakan.

3.3.1.1 Environment

Environment yang digunakan adalah *normal enemy arena* berisikan *digi-chest*, *destructible box* dan *wall*.

Tabel 3.23 Environment yang Digunakan

Komponen	Keterangan
Normal Arena (9m X 9.5m) : - Digi-Chest - Destructible Box - Wall	Normal Arena dengan ukuran $p \times l$ (9m X 9.5m) yang digunakan sebagai <i>environment</i> untuk <i>normal enemy</i> , dimana terdapat 3 objek yang dapat muncul berupa <i>digi-chest</i> , <i>destructible box</i> dan <i>wall</i> .

3.3.1.2 State

State yang digunakan adalah bagian dari *normal enemy*, yakni *idle*, *pathfinding*, *position of agent on the arena*, *attacking* dan *death*. *State* yang digunakan berkaitan dengan *policy* yang digunakan nantinya.

Tabel 3.24 State yang Digunakan

State	Keterangan
Idle	Normal Enemy melakukan <i>idle</i> (berdiam) sebelum berada pada <i>state</i> yang lain terlebih dahulu.
Pathfinding	Normal Enemy mencari jalan (<i>pathfinding</i>) untuk mengelilingi arena.

State	Keterangan
<i>Position of Agent on the Arena</i>	<i>Normal Enemy</i> sesudah melakukan <i>pathfinding</i> , mencari dan mendeteksi jika adanya pemain berdasarkan posisi <i>normal enemy</i> pada arena (<i>position of agent on the arena</i>).
<i>Attacking</i>	Setelah <i>normal enemy</i> mendeteksi pemain dan berhasil mengejar hingga mendekati pemain. Maka <i>normal enemy</i> memasuki <i>state</i> menyerang (<i>attacking</i>), dan menyerang jika pemain berada dalam jangkauan serangan dari masing-masing <i>normal enemy</i> .
<i>Death</i>	Jika <i>normal enemy</i> terkena cukup serangan dan darahnya (HP ≤ 0), maka <i>normal enemy</i> berada pada <i>state</i> mati (<i>dead</i>) dan menjatuhkan material untuk peningkatan karakter pemain.

3.3.2 Agent Action Observations

Kemudian pada tahapan ini menjabarkan *agent* dan *action* yang digunakan dalam penerapan. Berikut adalah *agent* dan *action* yang digunakan.

3.3.2.1 Agent

Agent yang digunakan adalah *normal enemy* berisikan *creep*, *humanoid* dan *bull*.

Tabel 3.25 *Agent* yang Digunakan

Komponen	Keterangan
<i>Normal Enemy</i> : - <i>Creep</i> - <i>Humanoid</i> - <i>Bull</i>	Ketiga <i>normal enemy</i> digunakan sebagai <i>agent</i> dalam <i>game</i> , dengan seluruh <i>normal enemy</i> memiliki fungsi <i>state</i> , <i>action</i> , <i>reward</i> yang sama.

3.3.2.2 Action

Action yang digunakan adalah *idle*, *patrolling*, *detecting*, *chasing*, *attacking* dan *dead* yang merupakan bagian *state* dan *policy* yang berkaitan pada *normal enemy*.

Tabel 3.26 *Action* yang Digunakan

Action	Keterangan
<i>Idle</i>	<i>Normal Enemy</i> melakukan <i>idle</i> (berdiam) sebelum melakukan <i>action</i> yang lain terlebih dahulu.
<i>Patrolling</i>	<i>Normal Enemy</i> melakukan <i>patrolling</i> (berpatroli) sesudah melakukan <i>idling</i> dan mencari jalan (<i>pathfinding</i>) untuk mengelilingi arena.
<i>Detecting</i>	<i>Normal Enemy</i> sesudah melakukan <i>patrolling</i> , mencari dan mendeteksi (<i>detecting</i>) pemain berdasarkan posisi <i>normal enemy</i> pada arena (<i>position of agent on the arena</i>).
<i>Chasing</i>	Setelah berhasil mendeteksi pemain, <i>normal enemy</i> memasuki mode mengejar pemain (<i>chasing</i>).
<i>Attacking</i>	Setelah <i>normal enemy</i> mendeteksi pemain dan berhasil mengejar hingga mendekati pemain. Maka <i>normal enemy</i> memasuki mode menyerang (<i>attacking</i>), dan menyerang jika pemain berada dalam jangkauan serangan dari masing-masing <i>normal enemy</i> .

Action	Keterangan
<i>Dead</i>	Jika <i>normal enemy</i> terkena cukup serangan dan darahnya ($HP \leq 0$), maka <i>normal enemy</i> mati (<i>dead</i>) dan menjatuhkan material untuk peningkatan karakter pemain.

3.3.3 Reward Value Mechanism

Tahapan ini mengacu pada Acuan *Reward Values* dan mengambil acuan dari mekanisme nilai *reward* dan *punishment* tersebut. Hal ini diperlukan untuk menyesuaikan lebih rinci lagi terhadap *state* dan *action* yang diambil oleh *agent*. Berikut adalah nilai acuan *policy* pelatihan pada Tabel 3.27.

Tabel 3.27 Acuan *Reward Values*

Nilai	Mekanisme <i>Reward</i>
$>+1$	<i>Agent</i> menerima <i>reward</i> yang sangat besar.
$+0.5 - 1$	<i>Agent</i> menerima <i>reward</i> yang besar.
$+0.005 - 0.5$	<i>Agent</i> menerima <i>reward</i> .
Nilai	Mekanisme <i>Punishment</i>
<-1	<i>Agent</i> menerima <i>punishment</i> yang sangat besar.
$-0.5 - 1$	<i>Agent</i> menerima <i>punishment</i> yang besar.
$-0.005 - 0.5$	<i>Agent</i> menerima <i>punishment</i> .

Nilai dari acuan mekanisme *reward values* didasari oleh penelitian yang berjudul “*Comparative Study of SAC and PPO in Multi-Agent Reinforcement Learning Using Unity ML-Agents*” tahun 2023. Penelitian ini menggunakan mekanisme *reward* dengan batas nilai $(1 - \epsilon, 1 + \epsilon)$ Batas ini digunakan untuk menstabilkan pelatihan dan memastikan bahwa tidak ada nilai yang berlebihan mempengaruhi saat dilakukan pelatihan. Selain itu, batas ini digunakan untuk menghindari istilah “*reward hacking*”. Istilah ini menurut Amodei mengacu ketika *agent* melakukan eksploitasi terhadap kelemahan dalam mekanisme *reward values* untuk memperoleh *reward* tinggi tanpa mempelajari atau menyelesaikan tugas dan *action* tersebut [42].

Dari nilai acuan tersebut terdapat ekspektasi tabel nilai *reward* awal untuk setiap *action* yang dilakukan oleh *agent*. Tabel nilai ini berfokus pada *action* apa saja yang mungkin terjadi jika nilai *reward* mencapai pada nilai tertentu. Meski begitu, tidak selamanya *action* tersebut muncul saat nilai *cumulative reward* sudah mencapai jarak nilai yang dapat dilakukan oleh *action*, karena sifat dinamis dari *reinforcement learning* dan skenario yang tidak selalu sama. Berikut adalah tabel ekspektasi *action* yang mungkin terjadi berdasarkan nilai *reward* dan *punishment*.

Tabel 3.28 Tabel Ekspektasi *Action* yang Mungkin Terjadi Berdasarkan Nilai *Reward*

<i>Action</i>	Nilai	Keterangan
<i>Idle</i>	0	Karena <i>action</i> ini merupakan <i>action</i> awal yang dilakukan oleh <i>agent</i> , maka nilai ekspektasinya adalah 0 atau minus jika <i>agent</i> tidak bergerak sama sekali.
<i>Patrolling</i>	$0.005 - 1$	Jika <i>agent</i> berhasil melakukan <i>patrolling</i> dan mengelilingi <i>arena</i> , maka nilai ekspektasinya dari $0.005 - 1$, karena jika <i>agent</i> melakukan <i>patrolling</i> terus menerus, maka nilai <i>cumulative reward</i> bertambah.
<i>Detecting</i>	$0.5 - 1$	Jika <i>agent</i> berhasil melakukan <i>detecting</i> saat melakukan patroli, maka nilai ekspektasinya dari $0.5 - 1$, karena jika <i>agent</i> melakukan <i>detecting</i> setelah melakukan <i>patrolling</i> , maka nilai <i>cumulative reward</i> bertambah.
<i>Chasing</i>	$0.5 - 1$	Jika <i>agent</i> berhasil melakukan <i>chasing</i> setelah mendeteksi pemain, maka nilai ekspektasinya dari $0.5 - 1$, karena jika <i>agent</i> melakukan <i>chasing</i> setelah melakukan <i>detecting</i> , maka nilai <i>cumulative reward</i> bertambah.
<i>Attacking</i>	$1 +$	Jika <i>agent</i> berhasil melakukan <i>attacking</i> setelah mengejar pemain, maka nilai ekspektasinya dari $1 +$, karena jika <i>agent</i> melakukan <i>attacking</i> terus menerus maka nilai <i>cumulative reward</i> bertambah.

Tabel 3.29 Tabel Ekspektasi *Action* yang Mungkin Terjadi Berdasarkan Nilai *Punishment*

<i>Action</i>	Nilai	Keterangan
<i>Patrolling</i>	$-0.005 - -1$	Jika <i>agent</i> berhasil melakukan <i>patrolling</i> dan mengelilingi <i>arena</i> , maka nilai ekspektasinya dari $-0.005 - -1$, karena jika <i>agent</i> melakukan <i>patrolling</i> terus menerus, maka nilai <i>cumulative reward</i> bertambah.
<i>Detecting</i>	$-0.5 - -1$	Jika <i>agent</i> berhasil melakukan <i>detecting</i> saat melakukan patroli, maka nilai ekspektasinya dari $-0.5 - -1$, karena jika <i>agent</i> melakukan <i>detecting</i> setelah melakukan <i>patrolling</i> , maka nilai <i>cumulative reward</i> bertambah.
<i>Chasing</i>	$-0.5 - -1$	Jika <i>agent</i> berhasil melakukan <i>chasing</i> setelah mendeteksi pemain, maka nilai ekspektasinya dari $-0.5 - -1$, karena jika <i>agent</i> melakukan <i>chasing</i> setelah melakukan <i>detecting</i> , maka nilai <i>cumulative reward</i> bertambah.
<i>Dead</i>	-1	Jika <i>agent</i> mati/ <i>dead</i> , maka nilai ekspektasinya -1 , karena <i>agent</i> setelah <i>dead</i> tidak melakukan <i>action</i> kembali.

Kemudian terdapat juga *policy* yang di khususkan saat melakukan pelatihan. Di mana *policy* pelatihan ini, mengambil dari apa saja yang bisa dilakukan oleh *agent* seperti *action*, *state*, *environment* yang mempengaruhi dan juga mengambil referensi dari penelitian sebelumnya sebagai acuan karena merupakan *game* aksi dan memiliki *policy* yang bisa disesuaikan dengan *policy* pada *game Code Crusader* [42]. Dalam *policy* ini, terdapat *reward* dan *punishment* yang diberikan ketika *agent*

membuat suatu *action* atau langkah yang diambil. Berikut adalah *policy* pelatihan pada *agent* musuh yang digunakan pada Tabel 3.30.

Tabel 3.30 *Policy* Pelatihan pada *Normal Enemy* dengan *Reward Values*

<i>Policy</i>	<i>Reward Value</i>
1. Jika <i>agent normal enemy</i> , kesulitan dalam bergerak atau tidak bergerak sama sekali setelah 50 langkah atau lebih dari 2 detik, maka iterasi <i>training</i> (pelatihan) dilewati.	<i>Iteration skipped</i>
2. Jika <i>agent</i> tidak bergerak sama sekali, <i>agent</i> mendapatkan <i>punishment</i> .	− 0.010 (<i>Step</i>)
3. Jika <i>agent</i> mendekati tembok atau <i>obstacle</i> maka <i>agent</i> mendapatkan <i>punishment</i> yang besar.	− 0.20 (<i>Step</i>)
4. Jika <i>agent</i> berhasil bergerak dan berpatroli mengelilingi arena, maka <i>agent</i> diberikan <i>reward</i> .	+ 0.005 (<i>Step</i>)
5. Jika <i>agent</i> berhasil menyelesaikan satu rotasi patroli dalam arena, maka <i>agent</i> diberikan <i>reward</i> .	+ 0.5
6. Jika <i>agent</i> gagal bergerak dan berpatroli mengelilingi arena, maka <i>agent</i> diberikan <i>punishment</i> berupa <i>punishment</i> .	− 0.01 (<i>Step</i>)
7. Jika <i>agent</i> berhasil mendekati pemain, maka <i>agent</i> mendapatkan <i>reward</i> .	+ 0.01
8. Jika <i>agent</i> gagal mendekati pemain, maka <i>agent</i> mendapatkan <i>punishment</i> .	− 0.05 (<i>Step</i>)
9. Jika <i>agent</i> berhasil mendeteksi pemain saat melakukan patroli, maka <i>agent</i> mendapatkan <i>reward</i> .	+ 0.5
10. Jika <i>agent</i> mengejar pemain setelah mendeteksi pemain maka <i>agent</i> mendapatkan <i>reward</i> .	+ 0.010 (<i>Step</i>)
11. Jika <i>agent</i> berhasil mengejar pemain maka <i>agent</i> mendapatkan <i>reward</i> yang besar.	+ 0.5
12. Jika <i>agent</i> tidak mengejar pemain maka <i>agent</i> mendapatkan <i>punishment</i> .	− 0.05 (<i>Step</i>)
13. Jika setelah mengejar pemain <i>agent</i> menyerang pemain, maka <i>agent</i> mendapatkan <i>reward</i> yang besar.	+ 0.5
14. Jika <i>agent</i> tidak langsung menyerang pemain, maka <i>agent</i> mendapatkan <i>punishment</i> .	− 0.01 (<i>Step</i>)
15. Jika serangan <i>agent</i> tidak mengenai pemain, maka <i>agent</i> mendapatkan <i>punishment</i> .	− 0.1
16. Jika <i>agent</i> terkena serangan oleh pemain, maka <i>agent</i> mendapatkan <i>punishment</i> yang besar.	− 0.5
17. Jika <i>agent</i> setelah menyerang berhasil dan menang melawan pemain, maka <i>agent</i> mendapatkan <i>reward</i> yang sangat besar.	+ 1
18. Jika <i>agent</i> gagal menyerang dan kalah, maka <i>agent</i> mendapatkan <i>punishment</i> yang sangat besar.	− 1

Dalam tabel bagian *reward value*, yang dimaksudkan dengan (+/− angka (*step*)) adalah, nilainya bertambah atau berkurang per langkah. Sementara jika

angka tidak terdapat (*step*), maka nilai akan bertambah atau berkurang berdasarkan *action* yang dilakukan.

Setelah menjabarkan tabel *policy* pelatihan, terdapat tabel ekspektasi *cumulative reward* dalam skenario pelatihan. Tabel ini menggabungkan Tabel 3.28, Tabel 3.29 dan Tabel 3.30 untuk mencari *policy* pelatihan dari *action* mana yang *agent* pilih dalam jarak nilai *cumulative reward* tertentu. Hasil dari nilai *cumulative reward* untuk *policy* pelatihan yang bersifat *step*, didapatkan dari melakukan perkalian nilai *policy* pelatihan dengan 100 langkah/*timesteps* yang mengambil penelitian Openai berjudul “*Proximal Policy Optimization Algorithms*,” Jul. 2017, yang di mana *state* dan *action agent* bervariasi setiap 200 *steps*, dan diambil nilai tengah 100 sebagai contoh perhitungan, serta nilai $V(s_{t+1}) = 0.250$ yang diambil dari *neural network critic* setelah melakukan *action* dan $V(s_t) = 0.300$ dari *neural network critic* sebelum melakukan *action* [37]. Tabel ini juga menjelaskan kemungkinan apa yang dilakukan *agent* berikutnya setelah melakukan *action* dari suatu *policy*. Berikut adalah ekspektasi *policy* dan *action* yang mungkin terjadi berdasarkan nilai *cumulative reward* pada Tabel 3.31.

Tabel 3.31 Ekspektasi *Policy* dan *Action* yang Mungkin Terjadi Berdasarkan Nilai *Cumulative Reward*


No	Policy	Action	Cumulative Reward	Keterangan
1.	Jika <i>agent normal enemy</i> , kesulitan dalam bergerak atau tidak bergerak sama sekali setelah 50 langkah atau lebih dari 2 detik, maka iterasi <i>training</i> (pelatihan) dilewati.	<i>Idle Patrolling</i>	<i>Iteration Skipped</i>	Tidak terdapat ekspektasi <i>cumulative reward</i> karena episode/iterasi akan dilewat. Untuk <i>action</i> , terdapat 2 ekspektasi berupa <i>idle</i> karena <i>agent</i> tidak bergerak dan <i>patrolling</i> karena <i>agent</i> kesulitan dalam bergerak.
2.	Jika <i>agent</i> tidak bergerak sama sekali, <i>agent</i> mendapatkan <i>punishment</i> .	<i>Idle Patrolling</i>	-1	Secara <i>cumulative</i> , <i>agent</i> menerima <i>punishment</i> yang besar jika <i>agent</i> tidak bergerak sama sekali. Hal ini berkaitan dengan <i>action</i> yang dapat dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>idle</i> , karena <i>agent</i> tidak bergerak dan <i>patrolling</i> , karena <i>agent</i> tidak bergerak dan melakukan patroli.
3.	Jika <i>agent</i> mendekati tembok atau <i>obstacle</i> maka <i>agent</i> mendapatkan <i>punishment</i> yang besar.	<i>Patrolling</i>	- 20	Secara <i>cumulative</i> , <i>agent</i> menerima <i>punishment</i> yang sangat besar jika <i>agent</i> mendekati tembok atau <i>obstacle</i> . Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>patrolling</i> , dan <i>agent</i> mendekati tembok atau <i>obstacle</i> pada saat mencari rute patroli.
4.	Jika <i>agent</i> berhasil bergerak dan berpatroli mengelilingi arena, maka <i>agent</i> diberikan <i>reward</i> .	<i>Patrolling</i>	0.5	Secara <i>cumulative</i> , <i>agent</i> menerima <i>reward</i> yang besar jika <i>agent</i> berhasil bergerak dan berpatroli. Hal ini berkaitan dengan <i>action</i> yang sedang

No	Policy	Action	Cumulative Reward	Keterangan
				dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>patrolling</i> , dan <i>agent</i> berhasil mencari rute patroli.
5.	Jika <i>agent</i> berhasil menyelesaikan satu rotasi patroli dalam arena, maka <i>agent</i> diberikan <i>reward</i> .	<i>Patrolling</i>	+ 0.5	Secara <i>action</i> , <i>agent</i> menerima <i>reward</i> yang besar jika <i>agent</i> berhasil menyelesaikan satu rotasi patroli dalam arena. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>patrolling</i> , dan <i>agent</i> berhasil mencari rute patroli dan menyelesaikan satu rotasi dalam arena.
6.	Jika <i>agent</i> gagal bergerak dan berpatroli mengelilingi arena, maka <i>agent</i> diberikan <i>punishment</i> berupa <i>punishment</i> .	<i>Idle Patrolling</i>	- 1	Secara <i>cumulative</i> , <i>agent</i> menerima <i>punishment</i> yang sangat besar jika <i>agent</i> gagal bergerak dan berpatroli mengelilingi arena. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>idle</i> , karena <i>agent</i> hanya terdiam dan tidak mencoba mengelilingi arena serta <i>patrolling</i> , karena <i>agent</i> gagal mencari rute patroli jika <i>agent</i> berhasil bergerak.
7.	Jika <i>agent</i> berhasil mendekati pemain, maka <i>agent</i> mendapatkan <i>reward</i> .	<i>Detecting Chasing</i>	1	Secara <i>cumulative</i> , <i>agent</i> menerima <i>reward</i> yang sangat besar jika <i>agent</i> berhasil mendekati pemain. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>detecting</i> , karena <i>agent</i> berawal dari mendeteksi pemain. Kemudian <i>chasing</i> , karena <i>agent</i> mendekati pemain.
8.	Jika <i>agent</i> gagal mendekati pemain, maka <i>agent</i> mendapatkan <i>punishment</i> .	<i>Detecting Chasing</i>	- 10	Secara <i>cumulative</i> , <i>agent</i> menerima <i>punishment</i> yang sangat besar jika <i>agent</i> gagal mendekati pemain. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>detecting</i> , karena <i>agent</i> berawal dari mendeteksi pemain. Kemudian <i>chasing</i> , karena <i>agent</i> gagal mendekati pemain.
9.	Jika <i>agent</i> berhasil mendeteksi pemain saat melakukan patroli, maka <i>agent</i> mendapatkan <i>reward</i> .	<i>Patrolling Detecting</i>	+ 0.5	Secara <i>action</i> , <i>agent</i> menerima <i>reward</i> yang besar jika <i>agent</i> berhasil mendeteksi pemain saat melakukan patroli. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>patrolling</i> , karena <i>agent</i> berawal dari berpatroli mengelilingi arena. Kemudian <i>detecting</i> , karena <i>agent</i> berhasil mendeteksi pemain.
10.	Jika <i>agent</i> mengejar pemain setelah mendeteksi pemain maka <i>agent</i> mendapatkan <i>reward</i> .	<i>Detecting Chasing</i>	2	Secara <i>cumulative</i> , <i>agent</i> menerima <i>reward</i> yang sangat besar jika <i>agent</i> mengejar setelah mendeteksi pemain. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>detecting</i> , karena <i>agent</i> berawal dari mendeteksi pemain. Kemudian <i>chasing</i> , karena <i>agent</i> mengejar pemain.
11.	Jika <i>agent</i> berhasil mengejar pemain maka <i>agent</i> mendapatkan <i>reward</i> yang besar.	<i>Chasing</i>	+ 0.5	Secara <i>action</i> , <i>agent</i> menerima <i>reward</i> yang besar jika <i>agent</i> berhasil mengejar pemain. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>chasing</i> , karena <i>agent</i> berhasil mengejar pemain.

No	Policy	Action	Cumulative Reward	Keterangan
12.	Jika <i>agent</i> tidak mengejar pemain maka <i>agent</i> mendapatkan <i>punishment</i> .	<i>Chasing</i>	- 10	Secara <i>cumulative</i> , <i>agent</i> menerima <i>punishment</i> yang sangat besar jika <i>agent</i> mengejar setelah mendeteksi pemain. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>chasing</i> , karena <i>agent</i> tidak mengejar pemain.
13.	Jika setelah mengejar pemain <i>agent</i> menyerang pemain, maka <i>agent</i> mendapatkan <i>reward</i> yang besar.	<i>Chasing Attacking</i>	+ 0.5	Secara <i>action</i> , <i>agent</i> menerima <i>reward</i> yang besar jika <i>agent</i> berhasil mengejar dan menyerang pemain. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>chasing</i> , karena <i>agent</i> mengejar pemain dan <i>attacking</i> ketika <i>agent</i> berhasil menyerang pemain.
14.	Jika <i>agent</i> tidak langsung menyerang pemain, maka <i>agent</i> mendapatkan <i>punishment</i> .	<i>Attacking</i>	- 2	Secara <i>cumulative</i> , <i>agent</i> menerima <i>punishment</i> yang sangat besar jika <i>agent</i> tidak langsung menyerang pemain. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>attacking</i> karena <i>agent</i> tidak langsung menyerang pemain.
15.	Jika serangan <i>agent</i> tidak mengenai pemain, maka <i>agent</i> mendapatkan <i>punishment</i> .	<i>Attacking</i>	- 0.1	Secara <i>action</i> , <i>agent</i> menerima <i>punishment</i> jika <i>agent</i> tidak mengenai pemain. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>attacking</i> karena serangan dari <i>agent</i> tidak mengenai pemain.
16.	Jika <i>agent</i> terkena serangan oleh pemain, maka <i>agent</i> mendapatkan <i>punishment</i> yang besar.	<i>Attacking</i>	- 0.5	Secara <i>action</i> , <i>agent</i> menerima <i>punishment</i> yang besar jika <i>agent</i> terkena serangan oleh pemain. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>attacking</i> karena <i>agent</i> mencoba menyerang dan melawan pemain meski terkena serangan dari pemain.
17.	Jika <i>agent</i> setelah menyerang berhasil dan menang melawan pemain, maka <i>agent</i> mendapatkan <i>reward</i> yang sangat besar.	<i>Attacking</i>	+ 1	Secara <i>action</i> , <i>agent</i> menerima <i>reward</i> yang sangat besar jika <i>agent</i> berhasil menang melawan pemain. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>attacking</i> karena <i>agent</i> berhasil menang melawan pemain.
18.	Jika <i>agent</i> gagal menyerang dan kalah, maka <i>agent</i> mendapatkan <i>punishment</i> yang sangat besar.	<i>Attacking Dead</i>	- 1	Secara <i>action</i> , <i>agent</i> menerima <i>punishment</i> yang sangat besar jika <i>agent</i> kalah dan gagal menyerang pemain. Hal ini berkaitan dengan <i>action</i> yang sedang dilakukan <i>agent</i> pada <i>policy</i> ini berupa <i>attacking</i> karena <i>agent</i> berhasil sedang melawan pemain dan kalah. Kemudian <i>dead</i> , karena setelah <i>agent</i> kalah maka dia akan mati/ <i>dead</i> .

3.3.4 Hyperparameter

Kemudian, terdapat konfigurasi yang mengatur kombinasi nilai optimal parameter tertentu selama proses pelatihan model yang bernama *hyperparameter*. *Hyperparameter* telah diatur berdasarkan dokumen pemandu *unity ml agents* dan penelitian yang berjudul “*Comparative Study of SAC and PPO in Multi-Agent Reinforcement Learning Using Unity ML-Agents*” tahun 2023, dengan rekomendasi nilai untuk membantu optimasi pembelajaran dan performa pelatihan [36]. Berikut adalah *hyperparameter* yang telah dilakukan konfigurasi :



```

1 behaviors:|
2   NormalEnemy:
3     trainer_type: ppo
4     max_steps: 15000000
5     time_horizon: 256
6     summary_freq: 10000
7     threaded: true
8     hyperparameters:
9       batch_size: 2048
10      buffer_size: 20480
11      learning_rate: 0.0001
12      beta: 0.01
13      epsilon: 0.2
14      lambda: 0.95
15      num_epoch: 4
16      learning_rate_schedule: constant
17    network_settings:
18      normalize: true
19      hidden_units: 256
20      num_layers: 3
21    reward_signals:
22      extrinsic:
23        gamma: 0.99
24        strength: 1.0

```

Gambar 3.12 Hyperparameter

3.3.5 Policy and Update

Terakhir terdapat tahapan kemampuan pembaruan *policy*, tahapan ini mengambil seluruh *policy* yang terdapat pada *policy* pelatihan beserta *reward value*. Setelah itu, dilakukan pembaruan dari *policy* yang terjadi berdasarkan nilai *reward* pada *policy* pelatihan, untuk memperbarui parameter *policy* yang optimal. Pada perhitungan *policy pelatihan* ini mengambil referensi dari penelitian Openai berjudul “*Proximal Policy Optimization Algorithms*,” Jul. 2017 dan melakukan perkalian nilai *policy* pelatihan dengan 200 langkah/*timesteps*, yang di mana *state* dan *action agent* bervariasi setiap 200 *steps*, dan diambil nilai tengah 100 sebagai contoh perhitungan beserta nilai $V(s_{t+1})$, $V(s_t)$, $\pi_{\theta}(a_t|s_t)$ dan $\pi_{\theta_{old}}(a_t|s_t)$ [37]. Berikut adalah perhitungan *policy* pelatihan dan hasil pembaruannya dalam *policy update*.

3.3.5.1 Perhitungan Policy Pelatihan

- 1) Perhitungan *policy* “*agent normal enemy*, kesulitan dalam bergerak atau tidak bergerak sama sekali setelah 50 langkah atau lebih dari 2 detik, maka iterasi *training* (pelatihan) dilewati.” tidak akan dihitung, karena tidak memiliki nilai *reward* dan *policy* ini melewati iterasi *training*.
- 2) Perhitungan *policy* “jika *agent* tidak bergerak sama sekali, *agent* mendapatkan *punishment*”.

Tipe *reward* = *step*

Reward value = -0.01 (*step*)

Total *reward* = -1 (*reward* × 100 *step*)

Perhitungan ini, menjabarkan tipe *reward* (*step/action*), nilai *reward value* beserta contoh langkah/*steps*. Kemudian setelah mendapatkan nilai total *reward*, dilakukan perhitungan untuk mencari nilai TD (δ_t) (Rumus 2.2).

$$\delta_t = r + \gamma \times V(s_{t+1}) - V(s_t)$$

$V(s_{t+1}) = 0.250$ (dari *neural network critic* setelah melakukan *action*)

$V(s_t) = 0.300$ (dari *neural network critic*)

$\delta_t = -1 + 0.99 \times 0.250 - 0.300$